# 설계 검수·보완 보고서 — langchain-rag-research-agent (엣지 보존 인풋 아키텍처)

2026-11-07 · 검수자 Claude (Opus 5.5) · **상태: 검수 완료, 대표 결정 6개 대기**

## 0. 검수 범위와 기준

| 검수 대상 | 내용 |
|---|---|
| 추가 요구사항 3페이지 | 대표와 구글 AI가 정리한 엣지 보존 멀티 에이전트 인풋 아키텍처, 2대 노브(유사도·골든룰 보존) |
| 기존 설계 | `docs/MODULE_DESIGN.ko.md` v0.2 (보안·요약·검색 키워드 강화 모듈) |
| 실측 근거 | legal-intake B02b: 실제 E5 × memvid, 합성 안내문 10개·청크 30개·질문 30개 |
| 초안 다이어그램 | `docs/diagrams/01~05` (house-dark 양식) |

판정 기준은 네 가지입니다.

1. 원문 요구사항이 하나도 빠지지 않았는가.
2. 구현했을 때 실제로 동작하는가.
3. 기존 원칙(외부 전송 0, 합성 자료만, 유사도는 후보·확정은 게이트, 복사 금지)과 충돌하지 않는가.
4. 완료를 측정할 수 있는가.

원문 3페이지에는 대표 개인의 소송 정보가 들어 있습니다. 그래서 **원문 파일은 공개 저장소에 올리지 않고**, 이 문서에는 기술 요구사항만 옮겼습니다. 원문 끝의 구글 AI 개인 권유(소송·행정 서류 대리 작성)는 요구사항이 아니므로 제외했습니다.

---

## 1. 요구사항 추적표

판정: **반영**(원문 그대로) · **보완**(원문 의도를 지키면서 동작하게 고침) · **측정화**(보장 표현을 측정 지표로 바꿈) · **범위 밖**

| ID | 출처 | 요구사항 | 판정 | 보완 내용 (→ 지적 번호) |
|---|---|---|---|---|
| R01 | 1p | 30~40쪽 드래프트를 엣지 손실 없이 Llama·백본 에이전트 인풋으로 변환 | 측정화 | "손실 없음"은 보장할 수 없으므로 보호 항목 탈락 0과 골든 엣지 회수율로 측정 (F4) |
| R02 | 1p | 온톨로지 파서: LCEL + PydanticOutputParser + 정규식 | 보완 | 파서는 원문 구간에 라벨만 붙이고 재작성하지 않음, 실패 구간은 보존 (F5) |
| R03 | 1p | 온톨로지 5분류 | 반영 | `Core_Hypothesis` · `Tech_Architecture` · `Market_Positioning` · `Constraint_Guardrail` · `Action_Item` + 내부용 `Unclassified` |
| R04 | 1p | 일반 설명 문장과 고유 엣지 분리 | 보완 | 엣지 점수와 클리셰 감점으로 분리 (F3) |
| R05 | 1p | 희소-밀집 하이브리드: Dense(OpenAI text-embedding-3-large 또는 오픈소스) + Sparse(BM25/TF-IDF), 특이 키워드 가중치 상향 | 보완 | Dense는 E5 로컬 기본, OpenAI는 선택. 특이 키워드는 골든 키워드 사전으로 가점 (F1) |
| R06 | 1p | 상위 30개를 Cohere Rerank 또는 BGE-Reranker로 재정렬 | 보완 | BGE-Reranker 로컬 기본, Cohere는 선택. 리랭커는 관련도만 매기고 클리셰 판정은 별도 신호 (F1, F3) |
| R07 | 1p | 진부한 문장 필터, 수치·로직·특이점 문장 상위 배치 | 보완 | 엣지 점수 구성요소 6개로 구현 (F3) |
| R08 | 1p | LangGraph `AgentState` 5필드 | 보완 | 원래 5필드 이름 유지 + 필수 필드 추가 (F8) |

| ID | 출처 | 요구사항 | 판정 | 보완 내용 (→ 지적 번호) |
|---|---|---|---|---|
| R09 | 1p | `Chunk_Ingest` → `Edge_Filter` → `Token_Check`(조건) → `Token_Diet` → `Final_Synthesize` | 보완 | 반복 상한, 보호 항목 초과 시 정지·보고, 무근거 시 생성 0회 분기 추가 (F7) |
| R10 | 1p | 낮은 중요도 온톨로지부터 Token Diet | 반영 + 결정 | 감량 순서는 대표 결정 D4 |
| R11 | 1p | LangSmith Tracing: 온톨로지 분할·생존 엣지 문장을 타임라인으로 시각화 | 보완 | 허용 목록 필드만, 서빙은 업로드 0 (F18) |
| R12 | 1p | 평가: Claude 결과 vs Llama 파이프라인 결과 비교 | 보완 | 정답 기준은 사람이 표시한 골든 엣지. Claude는 비교 대상의 하나이고 선택 실행 (F10) |
| R13 | 1p | 자동 정량 평가(RunEval): 핵심 엣지 단어가 최종 인풋에 포함됐는가 | 보완 | 단어 일치 대신 원문 구간 ID 포함 여부로 판정 (F10) |
| R14 | 2p | 글자·토큰 수 기준 무지성 청킹 금지 | 보완 | 구조 경계 우선 + E5 512토큰 한계는 문장 경계 하위 분할로 처리 (F6) |
| R15 | 2p | 세션·아이디어 흐름의 인과관계를 그래프 노드로 연결 | 보완 | 링크 타입 4개와 생성 규칙, 감량 시 쌍 보존 규칙 정의 (F9) |
| R16 | 2p | 엣지 스코어링: 클리셰 가중치 하향, 고유 개념·반전 상향 | 보완 | 구성요소별 점수를 청크마다 기록해 설명 가능하게 (F3) |
| R17 | 2p | 우선순위 압축: 요약본이 아니라 핵심 인용구·논리 뼈대를 원문 그대로 전면 배치 | 반영 | 추출식 조립. 재작성은 노브② 낮을 때만 + 원문 외 숫자·ID 거절 |
| R18 | 2p | LangSmith로 엣지 누락·환각 지점 추적 | 반영 | 노드별 trace + 환각 검사 결과 기록 |
| R19 | 2p | 잘된 요약 vs 엣지 깎인 요약의 입출력 쌍을 데이터셋으로 쌓아 필터 튜닝 | 반영 | 쌍 데이터셋 형식과 튜닝 규칙(compare만 사용) 정의 |
| R20 | 3p | 노브 2개만 독립 조절: 노브① 유사도 임계값(창), 노브② 골든룰 보존 가중치(방패) | 보완 | 노브 외 값은 버전으로 고정하고 노출하지 않음. 두 노브의 상호작용 해소 (F11, F12) |
| R21 | 3p | 노브① High(예: 0.85 이상 초고순도) / Low(광범위 탐색) | 보완 | **고정 0.85는 쓰지 않음.** 노브 위치를 모델별 보정 임계값에 매핑 (F2) |
| R22 | 3p | 노브② High(클리셰 삭제, 골든 프레이즈 1순위) / Low(온톨로지 순 읽기 좋은 요약) | 반영 | High = 추출 전용, Low = 검사 조건부 요약 허용 |
| R23 | 3p | 프리셋: 소송·증거 타격(High·High), 지식 사업·AI 리서치(Low·High) | 반영 | 프리셋 2개는 원문. 법률 검색(High·Mid), 일반 요약(Low·Low)은 제안으로 별도 표시 |
| R24 | 3p | 두 파라미터로 RAG 라우팅과 프롬프트 가중치를 동적으로 제어하는 백엔드 로직 | 반영 | `Knobs` 계약 하나가 검색·점수·조립·요약 허용을 모두 결정 |
| U01 | 대표 | 검색이 필요한 모든 곳에서 재사용하는 모듈 | 보완 | 공개 인터페이스 3개 + LangChain·LangGraph 어댑터 (F20) |
| U02 | 대표 | legal-intake에서 뺀 검색 내용 통합 | 반영 | `app/rag`·`rag-runtime`·scripts·fixtures·tests·증거 이전 (M1) |
| U03 | 대표 | 이 저장소의 기존 검색 내용 통합 | 반영 | v0.2의 시나리오·계약·색인 수명주기·평가·위협 모델 유지 |
| U04 | 대표 | 마스킹은 legal-intake 보안 action과 공유 | 보완 | 정본은 legal-intake, 이 저장소는 프로토콜만 정의 (F14) |
| U05 | 대표 | Spring + FastAPI + memvid 하이브리드 내용은 spring-fastapi-async-refactor로 이전 | 반영 | `docs/hybrid/`로 이전, 여기서는 제거 |
| U06 | 대표 | 정한 flowchart 디자인 양식의 Mermaid 반영 | 반영 | `docs/diagrams/01~05`, mmdc PNG 렌더 |

| ID | 출처 | 요구사항 | 판정 | 보완 내용 (→ 지적 번호) |
|---|---|---|---|---|
| — | 1p | 세부 구현을 Spring Boot + FastAPI 하이브리드 연동으로 | 범위 밖 | 이 모듈은 프레임워크에 묶지 않음. Spring 연동은 ② 저장소 (F23) |
| — | 2·3p | nightcoder에 이식 | 범위 밖 | 사용처로만 기록 (F21) |
| — | 1~3p | 소송·행정 서류 대리 작성 권유 | 제외 | 요구사항 아님 |

**결과: 요구사항 24개 + 대표 요구 6개 = 30개 전부 반영.** 원문 그대로 반영 11개(원문 7 + 대표 요구 4), 보완 17개, 측정화 1개, 반영 + 대표 결정 1개(R10)입니다. 원문 의도를 버린 항목은 없습니다. 범위 밖은 2개, 제외는 1개입니다.

---

## 2. 핵심 지적과 보완안 (심각도 순)

### 🔴 치명 — 고치지 않으면 동작하지 않음

**F2. 노브① "유사도 0.85 이상"을 그대로 쓰면 E5에서 근거가 전부 거절됨** - 근거: legal-intake B02b 실측. E5에서 정답 문서의 1위 점수는 **0.79~0.80대**입니다. 비교 세트 근거 질문의 최저 top1은 0.7868이고, Q22 정답 1위는 0.8037이었습니다. 정답과 오답의 간격도 0.0136밖에 되지 않았습니다. - 문제: 코사인 점수의 분포는 모델마다 다릅니다. 0.85는 E5에서는 "전부 거절", 다른 모델에서는 "전부 통과"일 수 있습니다. 기존 v0.2도 E6 학습 트랙에서 "고정 0.8이 안 되는 이유"를 짚었고, `RelevanceRule`에 고정 기본값을 두지 않았습니다. - 보완: - 노브 위치(0~1)를 **모델 identity별로 골든셋 compare 세트에서 보정한 임계값 구간**에 매핑합니다. - Low 끝 = 근거 질문을 거의 다 살리는 τ - High 끝 = 무근거 오수용 0을 지키는 가장 보수적인 τ - 절대값 τ_abs와 간격 τ_gap 규칙(B02b 방식)을 함께 씁니다. - "0.85"는 예시 값으로만 문서에 남깁니다.

**F12. 두 노브가 독립적이지 않음: 노브①을 올리면 노브②가 지킬 엣지가 사라짐** - 문제: 노브①의 임계값 게이트가 먼저 후보를 자르기 때문에, 노브②가 아무리 높아도 이미 잘린 골든 프레이즈는 되살릴 수 없습니다. "독립 조절"이라는 요구(R20)가 실제로는 깨집니다. - 보완: **보호 후보 경로**를 따로 둡니다. - 골든 키워드 사전 일치 구간과 `Constraint_Guardrail` 구간은 노브① 게이트를 거치지 않고 후보에 합류합니다. 다만 노브②가 일정 값(제안 0.5) 이상일 때만입니다. - 노브①은 "일반 후보의 순도", 노브②는 "보호 후보의 생존과 배치"를 맡아서 역할이 겹치지 않습니다. - 다이어그램 02·04에 이 경로를 그립니다.

**F7. Token_Diet가 무한 반복하거나 조용히 자를 수 있음** - 문제: 보호 항목만으로 예산을 넘으면 감량할 대상이 없어서 계속 돕니다. 반대로 끝을 잘라버리면 엣지가 조용히 사라집니다. - 보완: - 반복 상한을 둡니다(제안: 온톨로지 분류 수 + 1회). - 보호 항목만 남았는데도 예산을 넘으면 `BUDGET_PROTECTED_OVERFLOW`**로 멈추고 보고**합니다. 사람이 예산을 늘리거나 보호 항목을 해제합니다. - 문자열 절단은 금지합니다. - 매 감량 회차에 무엇을 뺐는지 trace에 남깁니다.

**F1. 외부 전송 충돌: OpenAI 임베딩·Cohere Rerank·LangSmith·Claude 비교** - 문제: - 원문은 이 네 가지를 기본처럼 씁니다. 그러나 기존 원칙은 외부 전송 0이 기본입니다. - 드래프트에는 사업 아이디어와 개인 소송 정보가 들어 있습니다. - 소송·증거 모드에서 실제 자료가 외부로 나가면 되돌릴 수 없습니다. - 보완: - 모든 외부 부품을 **공급자 인터페이스** 뒤에 둡니다(`Embedder`, `Reranker`, `Tracer`, `Comparator`). 기본 구현은 로컬입니다: E5, BGE-Reranker, 로컬 JSONL trace. - 외부 공급자는 **실행 단위로 명시해서 켤 때만** 씁니다. 공유 마스킹을 통과한 텍스트만 보내고, 실행 기록에 전송 사실을 남깁니다. - **하드 규칙:** `litigation_evidence` 프리셋에서는 외부 공급자를 켜는 설정 자체를 거부합니다. - 정책 확정은 대표 결정 D1입니다.

### 🟠 중대 — 품질·보안 목표를 못 지킴

**F3. 리랭커는 클리셰 필터가 아님** - 문제: Cohere Rerank와 BGE-Reranker는 "질문과의 관련도"를 매기는 모델입니다. 진부한 문장도 질문과 관련 있으면 상위에 올라갑니다. 원문은 "리랭커 단계에서 진부한 문장이 걸러진다"고 썼지만 그렇게 동작하지 않습니다. - 보완: **엣지 점수를 리랭커와 분리한 별도 신호**로 만듭니다. 구성요소는 6개이고 모두 청크마다 기록합니다.

| 구성요소 | 측정 |
|---|---|
| 희소성 | 배경 코퍼스 대비 IDF. 흔한 단어가 많으면 낮음 |
| 골든 프레이즈 | 대표가 정의한 골든 키워드·용어 사전 일치 |
| 구체성 | 숫자·날짜·금액·좌표·ID·직접 인용 포함 |

| 구성요소 | 측정 |
|---|---|
| 인과·반전 표지 | "따라서·때문에·반면·하지만" 등 |
| 온톨로지 우선순위 | 분류별 사전 가중치 |
| 클리셰 감점 | 진부 문장 예시 묶음과의 임베딩 유사도 |

최종 점수 = `(1−w)·리랭커 관련도 + w·엣지 점수`이고, `w`가 노브②입니다. 구성요소 가중치는 쌍 데이터셋(R19)의 compare 세트로만 조정하고 버전으로 고정합니다.

**F5. 온톨로지 파서가 원문을 바꿀 위험** - 문제: PydanticOutputParser로 "JSON으로 파싱"하면 LLM이 문장을 다듬거나 합쳐서 원문 엣지가 바뀝니다. 40쪽을 한 번에 넣으면 비용이 크고 실패 범위도 커집니다. - 보완: - 파서 출력은 `{segment_id, label, confidence, rationale_code}`만 담습니다. **본문은 원문 구간의 오프셋으로 참조**하고 LLM이 쓴 텍스트를 쓰지 않습니다. - 처리 순서는 이렇습니다. 1. 정규식으로 결정적 표지를 먼저 분류합니다(예: "제약:", "TODO", 숫자 목표). 2. 남은 구간을 세그먼트 묶음 단위로 로컬 Llama에 넣어 라벨을 붙입니다. 3. 형식이 틀리거나 신뢰도가 낮은 구간은 `Unclassified`로 **보존**합니다. 삭제하지 않습니다. - 평가: 사람 라벨과의 일치율을 분류별로 개수로 보고합니다.

**F15. 드래프트 자체에 주입 문장이 있을 수 있음 (간접 프롬프트 주입)** - 문제: AI와 나눈 대화 드래프트에는 "앞의 지시를 무시하고…" 같은 지시문이 자연스럽게 들어 있습니다. 그대로 Llama 인풋에 넣으면 백본 에이전트가 그 지시를 따를 수 있습니다. - 보완: - 공유 `check_input_policy`를 **문서 프로필**로 구간마다 호출합니다. - 차단 구간은 인풋에서 빼고 "제외 구간 목록"으로 보고합니다. - 사용자 세션 위험 점수에는 넣지 않습니다(v0.2 규칙 유지, 오탐으로 잠기는 것 방지). - 최종 인풋은 **지시 블록과 자료 블록을 분리**합니다. 자료 블록은 "데이터로만 취급"하라고 표시합니다.

**F14. 마스킹 공유 방식이 정해지지 않음** - 현황: 이 저장소의 `guard/masking.py`는 학습용 패턴 3개(주민번호·이메일·전화)뿐이고, 파일 안에 "S1 `mask_personal_data`가 아니다"라고 적혀 있습니다. legal-intake의 `mask_personal_data`는 아직 미구현입니다(인수인계 문서 4절). - 보완: - **정본은 legal-intake** 하나입니다. - 이 저장소는 `Masker` · `InputPolicy` 프로토콜만 정의하고, 시험에는 가짜 구현을 씁니다. - legal-intake의 action이 완성되면 그 보안 모듈을 설치 가능한 하위 패키지로 분리합니다. 이 저장소는 그것을 의존성으로 씁니다(D3). - 그때까지 `guard/masking.py`는 **동결**합니다. 실제 자료 적재도 금지합니다. - `masking_version`을 색인 manifest에 기록합니다. 마스킹이 바뀌면 재색인합니다.

**F16. 공개 저장소에 개인 자료가 들어갈 위험** - 문제: 실제 드래프트와 원문 요구사항 3페이지에 개인 소송 정보가 있습니다. 소송 모드는 본질적으로 실제 사건 자료를 다룹니다. - 보완: - 공개 저장소에는 **합성 드래프트·합성 사건만** 둡니다. - 실제 자료는 `.gitignore`된 로컬 폴더에서만 처리합니다. 결과 증거 파일에는 원문·벡터를 넣지 않습니다. - 커밋 전 검사(시험)로 실제 자료 경로와 PII 패턴을 막습니다. - 확정은 D5입니다.

## 🟡 보통 — 모호해서 구현자가 임의로 정하게 됨

**F4. "유실 없는 압축", "단 1%도 깎지 않는", "완벽한 결과물"** - 보장할 수 없는 표현입니다. 대신 측정 지표로 바꿉니다(3절 완료 기준). - 보호 항목 탈락 0(하드) - 골든 엣지 회수율 n/총수 - 원문에 없는 숫자·ID 0

**F6. 무지성 청킹 금지 vs E5 512토큰 한계** - 처리 방법: 1. 구조 경계를 우선합니다: 제목, 대화 턴(대표/AI), 문단, 목록 항목. 2. 구조 단위가 512토큰을 넘으면 **문장 경계에서만** 하위 분할하고 `parent_segment_id`를 유지합니다. 3. 조립 단계에서는 부모 단위로 다시 묶을 수 있게 합니다. - 토큰은 E5 토크나이저로 셉니다(색인용). 예산 검사(Token_Check)는 **백본 모델 토크나이저**로 따로 셉니다.

**F8. AgentState 보완** - 원문 5필드는 이름 그대로 유지합니다: `raw_draft` · `ontology_mapped` · `filtered_context` · `token_count` · `final_prompt_input`. - 필수로 추가하는 필드: - 식별·설정: `request_id`, `task`, `knobs`, `preset` - 처리 결과: `segments`, `causal_links`, `candidates`, `edge_scores`, `protected_ids`, `excluded_segments` - 진행 상태: `diet_rounds`, `status` - 버전: `versions`(chunker, masking, policy, index, prompt, rule, golden) - 요청마다 새 상태를 씁니다. 공유 가변 상태는 금지합니다.

**F9. 인과관계 그래프의 정의** - 링크 타입 4개:

| 타입 | 뜻 |
|---|---|
| `causes` | 원인 → 결과 |
| `supports` | 근거 → 주장 |

| 타입 | 뜻 |
|---|---|
| `contradicts` | 서로 반대 |
| `supersedes` | 새 결정이 옛 결정을 대체 |

- 생성 규칙: 명시적 표지(정규식)와 인접 구간은 자동으로 만듭니다. LLM이 제안한 링크는 REVIEW 표시로만 둡니다.
- 감량 규칙: 링크로 묶인 쌍에서 한쪽만 남으면 "연결 끊김" 표시를 남깁니다. `supersedes` 로 대체된 옛 결정은 현재 결정보다 뒤에 배치합니다. v0.2의 "폐기안이 현재 결정보다 앞서지 않음" 규칙과 같습니다.

**F10. 평가 기준: Claude 결과는 정답이 아님** - 정답 기준은 **사람이 드래프트마다 표시한 "반드시 남길 구간" 목록**(골든 엣지)입니다. - Claude 직접 요약은 비교 대상(기준선)의 하나입니다. 실행하면 드래프트가 외부로 나가므로 선택 실행입니다(D1). - RunEval의 "엣지 단어 포함" 검사는 표면 단어 대신 **원문 구간 ID가 최종 인풋에 포함됐는지**로 판정합니다. 마스킹 치환과 동의어 때문에 단어 일치는 틀리기 쉽습니다. - 비교할 기준선: ① 앞부분 자르기, ② 글자 수 청킹 RAG, ③ Llama에 원문 직접, ④ Claude 직접 요약(선택), ⑤ 이 파이프라인.

**F11. "노브 2개" 원칙과 숨은 파라미터** - 사용자에게 보이는 값은 노브 2개와 프리셋뿐입니다. - 나머지는 **버전으로 고정한 설정**이고 노브로 노출하지 않습니다: 토큰 예산(백본 모델 창), 보호 규칙, 점수 구성 가중치, k 범위, 감량 순서. - 설정을 바꾸면 버전이 바뀌고, 평가 결과는 같은 버전끼리만 비교합니다.

**F13. 작업 설명(질문)이 없을 때 노브①의 의미** - 원문의 "드래프트 통째 → 마스터 프롬프트" 모드에는 검색 질의가 없습니다. - 보완: `task` 가 없으면 노브①은 **각 구간과 그 구간이 속한 온톨로지 분류 중심 벡터의 유사도**로 동작합니다. 분류 안의 대표성을 거르는 용도입니다. trace에 모드를 기록합니다.

**F17. 백본 모델과 토큰 예산 미정** - Llama 모델 ID·정밀도·서빙 방식은 legal-intake와 같이 대표 PC 사양으로 정합니다(Windows, RAM 16GB, RTX 5060 8GB). - 토큰 예산 = 모델 창 – 지시 블록 – 출력 여유분으로 계산하는 설정값입니다.

**F18. LangSmith 원격 전송** - 서빙: `serving_trace_guard()` 로 업로드 0을 유지합니다. 환경변수가 켜져 있어도 같습니다(기존 코드 유지). 같은 스키마로 로컬 JSONL에 기록합니다. - 실험: 합성 또는 마스킹 자료만, 허용 목록 필드만 원격으로 보냅니다. - 원문의 "어떤 엣지 문장이 살아남았는지 시각화"는 문장 본문 대신 **구간 ID·분류·점수 구성요소**로 표시합니다. 본문 확인은 로컬 뷰어로 합니다.

**F20. 재사용 인터페이스**

| 함수 | 용도 |
|---|---|
| `build_brief(draft, task=None, knobs=None, preset=None) -> Brief` | 긴 드래프트 → 백본 인풋 |
| `search(query, collection, knobs=None) -> RetrievalResult` | 일반 검색(법률 검색·안내 근거) |
| `build_graph(...)` | LangGraph 서브그래프. 다른 에이전트 그래프에 끼워 쓰기 |

- 어댑터: LangChain `BaseRetriever` , CLI, 선택형 FastAPI 내부 라우터.
- `Brief` 는 `final_prompt_input` , 포함 구간 ID, 제외 구간·사유, 버전, 상태를 담습니다.

## 🔵 참고

- **F19.** 원문에는 성공 기준 수치가 없습니다. 3절에서 정의합니다.
- **F21.** nightcoder 이식은 사용처로만 기록합니다.
- **F23.** 원문의 "Spring Boot + FastAPI 하이브리드 연동"은 ② 저장소의 범위입니다.
- **F24.** "상위 30"은 노브① Low 쪽 최대값으로 씁니다(High 쪽 8).
- **F25.** 한국어 BM25는 조사 제거(기존 구현)로 시작합니다. 형태소 분석기는 lab 실험 후보입니다.
- **F26.** 클리셰 감점용 "진부 문장 예시"와 배경 코퍼스는 합성 일반 문장 + 대표가 표시한 클리셰 예시로 만들고 버전으로 관리합니다.

- **F22. 다이어그램 자가 검수:** 02에 보호 후보 경로(F12)와 질의 없는 모드(F13)를 반영합니다. 04에 보호 후보 경로를 추가합니다. 05의 위로 향하는 화살표("완료 후 연결")는 예외로 본문에 설명합니다.

---

## 3. 완료 기준 (측정 가능)

| 범주 | 지표 | 기준 |
|---|---|---|
| 보존 | 보호 항목 탈락 수 | **0 (하드)** |
| 보존 | 골든 엣지 회수율 ( `n/총수` ) | 기준선 ①②③보다 높음, 합성 드래프트 confirm 세트 |
| 보존 | 인과 쌍 유지 · 끊김 표시 | 끊김 표시 없는 쌍 손실 0 |
| 보존 | 대체된 결정이 현재 결정보다 앞선 수 | 0 |
| 압축 | 토큰 예산 준수 | 100% 또는 `BUDGET_PROTECTED_OVERFLOW` 보고 |
| 클리셰 | 최종 인풋의 클리셰 표시 구간 비율 | 기준선보다 낮음 (개수로 보고) |
| 정확성 | 원문에 없는 숫자·날짜·ID (조립 결과·Llama 결과) | 0 |
| 정확성 | 인용 ID ⊂ 원문 구간 ID | 100% |
| 검색 | Hit@1 · Hit@3 · 무근거 혼동표 | B02b 재현 이상, 개수로 보고 |
| 보안 | 주입·PII 누출 | 0 |
| 보안 | 외부 연결 시도 (기본 설정) | 0, 대조군 시험 포함 |
| 분류 | 온톨로지 라벨 일치율 | 분류별 개수 보고, 기준은 D0에서 확정 |
| 노브 | 노브 조합별 결과 변화 | 프리셋 4개에서 지표 표 작성, 단조성 확인(노브① ↑ → 후보 수 ↓) |

표본이 작으므로 결과는 항상 `n/총수`로 적습니다. 기준값은 compare로만 정하고 confirm은 한 번만 씁니다.

---

## 4. 대표가 정할 것

| # | 결정 | 선택지 | 추천 |
|---|---|---|---|
| D1 | 외부 공급자 정책 | A 로컬 기본 + 실행 단위 명시적 켜기(마스킹 후, 소송 프리셋은 금지) / B 외부 기본 허용 / C 외부 완전 금지 | **A** |
| D2 | Python 패키지 import 이름 | A `rag_research_agent` / B `edge_rag` / C 저장소 이름 그대로 `langchain_rag_research_agent` | **A** (배포 이름은 `langchain-rag-research-agent` ) |
| D3 | 마스킹 공유 방식 | A legal-intake 보안 모듈을 설치 가능한 하위 패키지로 분리해 의존 / B legal-intake 전체를 git 의존성으로 / C 공용 보안 저장소 신설 | **A** (그 전에는 프로토콜 + 가짜 구현) |
| D4 | Token_Diet 감량 순서 (먼저 빠지는 순) | 프리셋별 기본안: `Unclassified` → `Market_Positioning` → `Tech_Architecture` → `Action_Item` → `Core_Hypothesis` . `Constraint_Guardrail` ·골든 프레이즈는 보호 | 리서치 프리셋은 기본안. 소송 프리셋 순서는 대표가 지정 |
| D5 | 실제 자료 처리 | A 공개 저장소는 합성만, 실제 자료는 로컬 `.gitignore` 폴더 / B 실제 자료용 비공개 저장소 별도 | **A** (상업화 단계에서 B) |
| D6 | legal-intake 연결 시점 | A legal-intake 과제 완료 후 라이브러리로 연결(API 추가 없음) / B 연결하지 않음 | **A** |

v0.2의 "대표가 정할 것" 4개는 이번 계획으로 정리됩니다. - 1번(패키지 이름): 저장소 이름은 정해졌고, import 이름만 D2로 남습니다. - 2번(①과의 관계): ①의 검색 코드를 여기로 옮기는 것으로 정해졌습니다. - 3번(lab 공개): 기존 추천대로 공개, 합성 자료만입니다. - 4번(하이브리드 문서): ② 저장소로 옮깁니다.

---

## 5. 원문 대비 바뀐 점 요약

| 원문 | 보완 후 |
|---|---|
| 유사도 0.85 이상 | 모델별 보정 임계값에 노브 위치를 매핑 |
| 리랭커가 클리셰를 거름 | 리랭커는 관련도만, 클리셰·엣지는 별도 점수 6요소 |
| 노브 2개 독립 | 보호 후보 경로를 둬서 실제로 독립 |
| 유실 없는 압축 | 보호 항목 탈락 0(하드) + 회수율 측정 + 초과 시 정지·보고 |
| OpenAI·Cohere·LangSmith·Claude 기본 사용 | 로컬 기본, 외부는 명시적으로 켤 때만, 소송 모드는 외부 금지 |
| 파서가 JSON으로 재구성 | 라벨만 붙이고 원문 오프셋 참조, 실패 구간 보존 |
| Claude 결과와 비교해 평가 | 사람이 표시한 골든 엣지가 정답, Claude는 선택 기준선 |
| 인과관계 연결 | 링크 타입 4개 + 생성 규칙 + 감량 시 쌍 규칙 |
| 별도 언급 없음 | 간접 주입 차단, 지시·자료 블록 분리, 공개 저장소 데이터 규칙 |

## 6. 다음 단계

1. 대표 결정 D1~D6
2. 결정 반영해 `README.md`(한국어) · `README.en.md` · `docs/DESIGN.ko.md` v1.0 작성. 다이어그램 02·04 보완 반영
3. 하이브리드 문서를 spring-fastapi-async-refactor `docs/hybrid/`로 이전
4. legal-intake 문구 수정(새 저장소 이름, 마스킹 공유)
5. 기존 Codex 인수인계 문서와 통합한 최종 인수인계 문서 작성